

ALGORITMI E PROGRAMMAZIONE PER L'ANALISI DEI DATI 2025-2026

Analisi del dataset DBLP con grafi e sketch

QUESTION 1.I, 2.(ii), 3.I, 4.2 e 5

AUTORE

Lorenzo Yang

OUTPUT

Grafo bipartito, Bottom-k, BFS campionate

TRACCIA E MODELLO

Dal CSV al grafo bipartito

- Ogni pubblicazione e' un nodo.
- Ogni autore e' un nodo.
- Un arco collega autore e pubblicazione scritta.
- I nodi hanno attributi: anno, titolo, venue, publisher.

7

DATASET

8

LIMITI TEMPORALI

21M

ARCHI NEL GRAFO UNIONE

Autori

Pubblicazioni

A1

P1

A2

P2

A3

P3

IMPLEMENTAZIONE

Lettura a chunk e ID numerici

```
reader = pd.read_csv(
    csv_path,
    sep=";",
    usecols=usecols,
    chunksize=100_000,
)

for chunk in reader:
    for row in chunk.itertuples(index=False, name=None):
        pub_node = _add_node(...)
        for author_name in split_authors(row[author_index]):
            graph.add_edge(_add_node(...), pub_node)
```

- 1 Carico solo colonne necessarie.
- 2 Converto autori e pubblicazioni in ID numerici.
- 3 Salvo attributi utili sui nodi pubblicazione.
- 4 Evito caricamenti completi dei CSV grandi.

QUESTION 1.I

Autore con piu' pubblicazioni scritte da solo

- 1. Filtro le pubblicazioni con anno minore o uguale a x.
- 2. Controllo i vicini della pubblicazione.
- 3. Se c'e' un solo autore incremento il suo contatore.
- 4. Scelgo il massimo, con tie-break alfabetico.

Tempo totale Q1.I: **175,150 s**

RISULTATI A YEAR_LIMIT = 2023		
DATASET	AUTORE	SINGOLE
article	T. D. Wilson 0001	347
book	John A. Vince	21
incollection	Gerrit Bleumer	71
inproceedings	Ichiro Satoh	118
mastersthesis	Adams Wei Yu	1
phdthesis	Mohammad Jafari	3
proceedings	Bruce L. Jacob	1

QUESTION 2.(II)

Bottom-k sketch

Lo sketch conserva i k elementi con ranking hash piu' piccolo.

SIZE

$$|A| \approx (k - 1) / kth(A)$$

JACCARD

frazione comune nello sketch dell'unione

- Universo: stringhe.
- Ranking implicito: hash in $[0, 1)$.
- Sketch confrontabili: stesso k e stesso seed.
- Uso dichiarato di ChatGPT come supporto per implementazione e spiegazione.

```
def update(self, element):
    element = str(element)
    if element in self._ranks:
        return

    rank = self._rank(element)
    if len(self._ranks) < self.k:
        self._ranks[element] = rank
        return

    worst = max(self._ranks, key=self._ranks.get)
    if rank < self._ranks[worst]:
        del self._ranks[worst]
        self._ranks[element] = rank
```


QUESTION 3.I

Autori distinti: esatto vs Bottom-k

K = 512

DATASET	ESATTO	STIMA	ERRORE
article	2.200.876	2.252.006	2,32%
book	20.808	20.205	2,90%
incollection	81.419	82.725	1,60%
inproceedings	2.130.704	2.328.231	9,27%
mastersthesis	21	21	0,00%
phdthesis	109.843	96.366	12,27%
proceedings	18	18	0,00%

ERRORE RELATIVO CON K = 512



Aumentare k migliora in generale la stima, ma con un singolo seed non impone monotonia perfetta.

QUESTION 3.I

Jaccard tra insiemi di autori

La similarita' piu' alta e' tra **article** e **inproceedings**: molti autori pubblicano sia su riviste sia in conferenze.

K

512

TEMPO Q3.I

211,471 s

COPPIE PIU' INFORMATIVE

COPPIA	ESATTO	STIMA	ERR. ASS.
article - inproceedings	0,317	0,293	0,024
book - incollection	0,064	0,047	0,017
article - phdthesis	0,032	0,027	0,005
incollection - inproceedings	0,031	0,029	0,001

QUESTION 4.2

Distanza media nella componente connessa piu' grande

1. Costruisco il sottografo fino all'anno x.
2. Trovo la componente connessa piu' grande.
3. Campiono fino a 16 nodi.
4. Eseguo BFS da ogni nodo campionato.
5. Media delle distanze raggiunte.

```
sampled_nodes = random_generator.sample(nodes, sample_count)

total = 0
for source in sampled_nodes:
    distances = bfs_distances(graph, source)
    total += sum(distances.values())

return total / (sample_count * (n - 1))
```

Parte piu' costosa: BFS ripetute su grafi con milioni di nodi.


QUESTION 4.2

Risultati principali per dataset

YEAR_LIMIT = 2023

DATASET	NODI	NODI LCC	DIST.
article	5.356.567	4.920.082	10,083
book	40.719	199	8,748
incollection	151.028	53.543	21,199
inproceedings	5.367.426	5.052.388	10,067
mastersthesis	42	2	1,000
phdthesis	219.771	5	2,000
proceedings	54.499	8	1,750

DISTANZA MEDIA STIMATA



Article e inproceedings formano componenti giganti; incollection mostra distanze medie piu' alte.

QUESTION 5

Grafo unione: crescita e distanza

9.972.422

NODI NEL 2023

9.301.176


NODI LCC NEL 2023

5,899 -> 9,657

DISTANZA MEDIA STIMATA

Il grafo unione riusa gli stessi ID per autori uguali e mantiene distinte le pubblicazioni per dataset.

DISTANZA MEDIA STIMATA - Q5/Q4.2



Corrisponde alla tabella "Ripetizione di QUESTION 4.2 sul grafo unione".

QUESTION 5

Author graph

Nel grafo degli autori, due autori sono collegati se hanno scritto almeno una pubblicazione insieme.

```
for author_a, author_b in combinations(authors, 2):
    if author_graph.has_edge(author_a, author_b):
        author_graph[author_a][author_b]["weight"] += 1
    else:
        author_graph.add_edge(author_a, author_b, weight=1)
```

COPPIA CON PIU' COLLABORAZIONI

Makoto Takizawa 0001
Tomoya Enokido

519


PUBBLICAZIONI INSIEME

3.326.059
nodi autori

20.355.908
archi collaborazione

TEMPI E CONCLUSIONI

Cosa e' costato di piu'



Modello unico	Il grafo bipartito supporta tutte le question scelte.
Sketch	Bottom-k riduce memoria e permette stime di size e Jaccard.
Campionamento	La distanza media diventa trattabile anche su componenti molto grandi.
Collo di bottiglia	Q4.2 domina i tempi per le BFS ripetute.